Bergen Traffic Predictor

TODO: Navn på gruppemedlemmer

25. oktober 2026

Kort sammendrag. Bergen Traffic Predictor predikerer biltrafikk én time frem ved Danmarks plass. Kronologiske eksperimenter viste at værdata fra Frost ikke forbedret resultatene, og sluttmodellen bruker derfor kalender og historisk trafikk. På den tidligere ubrukte perioden 2026 H1 fikk modellen MAE 108,81 kjøretøy/time, mot 211,79 for forrige-uke-baselinen på de samme 4 343 tidspunktene. Sluttproduktet er en lokal Streamlit-demonstrasjon for ett målepunkt.

1 Beskriv problemet

1.1 Omfang

Bergen Traffic Predictor estimerer hvor mange kjøretøy som passerer ett bestemt trafikkregistreringspunkt i løpet av neste time. Punktet er Danmarks plass med ID `14630V805616`. Hver modellrad representerer et tidspunkt t, mens *target* er observert trafikkvolum ved $t + 1$. Oppgaven er dermed *supervised regression* og en kortsiktig tidsserieprognose.

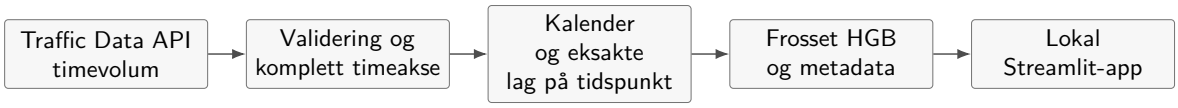
Prosjektets opprinnelige hypotese var at historiske værdata fra MET Norways Frost API kunne forbedre prediksjonene. Værvariantene tapte i kronologisk validering, så sluttmodellen ble værfri som følge av eksperimentene.

En videreutviklet løsning kan gi trafikkplanleggere og analytikere et anslag for belastningen ved punktet. Den manuelle referansen er trafikken på samme klokkeslett én uke tidligere, eventuelt justert skjønnsmessig for helg eller ferie. Dette er prosjektets baseline. Maskinlæring er relevant fordi trafikken varierer med time, ukedag og kalenderhendelser, og fordi flere historiske lag kan samvirke ikke-lineært. Modellen mangler likevel informasjon om blant annet ulykker, vegarbeid og arrangementer.

Prognosen kan brukes til å oppdage avvik fra et normalt ukemønster eller som ett av flere grunnlag for planlegging. Studentprosjektet har imidlertid ikke undersøkt faktisk beslutningsbruk, brukertall eller økonomisk gevinst. Løsningen demonstrerer derfor teknisk gjennomførbarhet, ikke dokumentert nytte eller lønnsomhet i drift.

Avgrensningen til ett punkt og én times horisont gjør dataløpet og evalueringen entydig. Modellen sier ikke noe om reisetid, kølengde eller retning og kan ikke overføres direkte til andre målepunkter med andre trafikkmønstre.

Figur 1 viser systemgrensen. Traffic Data API leverer aggregerte timesmålinger med kvalitetsparametere [1]. Prosjektet normaliserer serien, bygger modellvariabler fra eksakte tidspunkter, trener modellen og bruker den i Streamlit. Trening og app deler feature-kode, mens datakvalitet og publiseringsforsinkelse avgjør om en prognose kan lages.



Figur 1: Implementert dataløp fra offentlige trafikkdata til lokal demonstrasjon.

Prosjektet regnes som vellykket dersom en lekkasjesikker modell slår forrige-uke-baselinen på en senere, urørt periode, kan bygges reproduserbart og gir enten prognose eller tydelig feilmelding. Flerårige timedata og HGB-modellen kan håndteres på en vanlig bærbar datamaskin. Den viktigste ressursen er utviklingsarbeid til datavalidering, lekkasjekontroll, evaluering og integrasjon. En produksjonsløsning ville i tillegg krevd driftsansvar, overvåking og rutiner for godkjenning av nye modellversjoner.

1.2 Metrikker

Hovedmetrikken er gjennomsnittlig absolutt feil, MAE,

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|. \tag{1}$$

MAE måles i kjøretøy per time og kan tolkes direkte. RMSE rapporteres som støttemål fordi kvadreringen gir større utslag for enkelte store feil:

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}. \tag{2}$$

Modell og baseline måles på de samme prognoseradene. Vi rapporterer også antall prediksjoner og feil etter time og ukedag. Felles rader hindrer at en metode får et enklere evalueringsutvalg fordi den mangler færre lag. Programvaren testes for reproduserbar bygging, modellasting, manglende lag, API-feil og tidssoner. Svartid, oppetid og brukertilfredshet er ikke målt i den lokale demonstrasjonen.

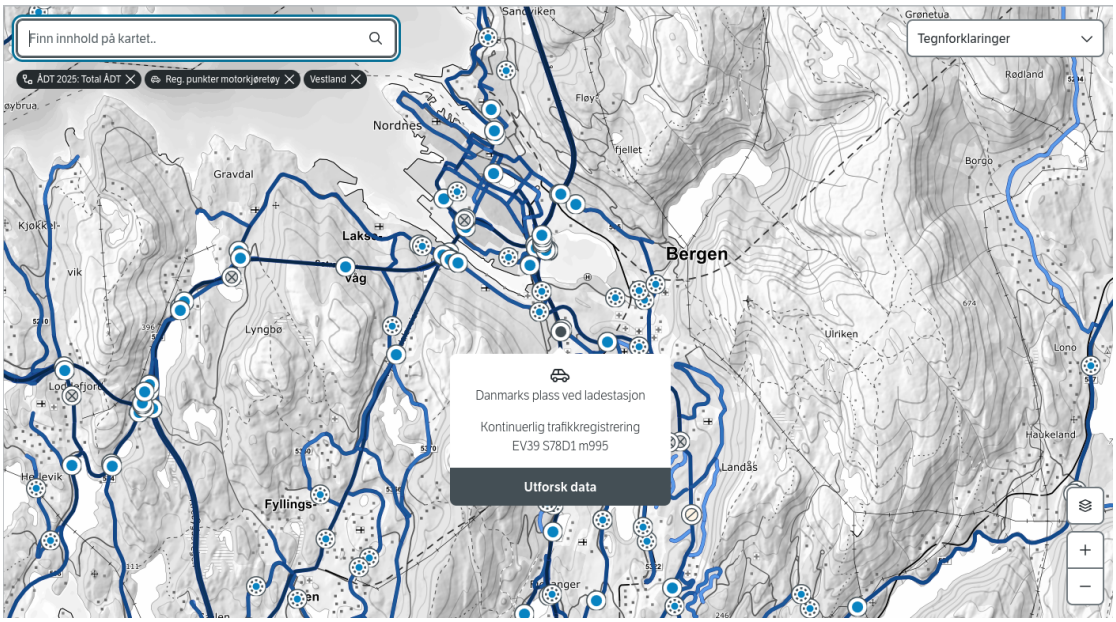
2 Data

2.1 Kilde, periode og targetverdier

Trafikkdata hentes fra Statens vegvesens åpne Traffic Data API, som inneholder aggregerte registreringer fra offentlige veger [2]. Uttrekket dekker 1. januar 2022 til 1. juli 2026 i lokal tid og gjelder feltet «Totalt» ved punkt `14630V805616`. Den normaliserte timeaksen har 39 407 timer, hvorav 38 956 har observert trafikkvolum og 451 mangler verdi. Perioden 2022–2025 brukes til utvikling og trening, mens 4 343 observerte timer i 2026 H1 reserveres til sluttevaluering.

Targetverdien lages uten manuell merking: For en modellrad ved t slås `traffic_volume` ved nøyaktig $t + 1$ opp som `target_traffic`. Trafikkmåleren er dermed både datakilde og fasit, men sensorfeil og ufullstendig dekning kan påvirke begge. Pipelinen krever gyldig tidspunkt og et ikke-negativt volum. Rådata og modellartefakter er utelatt fra Git, men kan gjenskapes med `make build-app-model`.

Kvalitetsrapporten finner ingen dupliserte tidspunkter og markerer rader uten volum som ugyldige. API-ets kvalitetsinformasjon lagres sammen med rådataene. Dette gir en reproduserbar kontroll av labelgrunnlaget, men kan ikke utelukke alle sensorfeil.



Figur 2: Geografisk oversikt over registreringsområdet ved Danmarks plass i Statens vegvesens Trafikkdataportal. Skjermbildet viser portalens kartvisning og valgte målested.

2.2 Rensing og målegap

Tid konverteres til tidssonebevart UTC og kontrolleres for ugyldige og dupliserte tidspunkter. Kalenderinformasjon beregnes i `Europe/Oslo`, slik at tidsaksen er entydig gjennom sommertid og vintertid, men kalenderverdiene er lokale.

De 451 manglende timene ligger i to dokumenterte gap i 2022 og 2024. Pipelinen oppretter en komplett timeakse og lar verdiene stå som manglende; de settes ikke til null, interpoleres eller erstattes. Null er en observasjon, mens en manglende verdi betyr at volumet er ukjent.

Det første gapet varer 67 timer fra 4. til 7. juni 2022, og det andre varer 384 timer fra 2. til 18. oktober 2024. Blant observerte timer i hele datasettet er minimum 40 og maksimum 4 235 kjøretøy; ingen observerte timer har volum null.

Datautforskingen viste et tydelig døgn- og ukemønster. For 2022–2025 var gjennomsnittet høyest kl. 15 med 3 426 kjøretøy per time og lavest kl. 03 med 185. Helgesnittet var 1 275, som var 32,5 prosent lavere enn hverdagssnittet på 1 889. Dette begrunner kalenderfeatures og ukebaselinen, men brukes ikke som en alternativ fasit.

Lag og target hentes ved eksakte tidspunkter, ikke ved å flytte et antall rader. Modellrader med manglende trafikklag eller target fjernes før trening og evaluering. Dermed kan ingen observasjon flyttes over et hull i serien.

2.3 *Feature engineering*

Sluttmodellen bruker 14 *features*. Seks beskriver lokal kalender: time, ukedag, måned, helg samt sinus og cosinus av time. Fem indikatorer markerer offentlig helligdag, dag før og etter helligdag, jul og nyttår samt 17. mai. De tre trafikklagene er observert volum ved nøyaktig $t-24$, $t-48$ og $t-168$. Alle er tilgjengelige, eller kan konstateres som manglende, når prognosen lages. Den trebaserte modellen krever ingen skalering. Trafikklagene følger absolutte tidsforskjeller i UTC, mens kalenderfeatures beregnes i lokal tid. Sinus og cosinus gjør at time 23 og 00 ligger nær hverandre i modellens representasjon.

Historiske temperatur-, nedbør- og vindmålinger ble hentet fra Frost for Bergen–Florida (SN50540) [3]. Bare forsinkede målinger ble brukt, fordi `referenceTime` er observasjonstid og ikke publiseringstid [4]. Værvariantene ga dårligere valideringsmål og inngår ikke i sluttmodellen eller appen. Manglende værmålinger ble bevart som manglende og ikke imputert.

2.4 Personvern og etikk

Datasettet inneholder aggregerte passeringstall, ikke kjøretøy- eller personidentifikatorer, så personvernrisikoen er lav. Ett punkt representerer likevel ikke all trafikk i området, og ukjente hendelser kan gjøre prognosen misvisende. Appen oppgir derfor punkt-ID, datakilde og begrensning. Ved eventuell operativ bruk må ansvar for beslutninger, datalisens og sensorendringer dokumenteres.

3 Modellering

3.1 Fra værhypotese til frosset kandidat

Forrige-uke-baselinen bruker observasjonen ved $(t+1)-168 = t-167$, samme target-time én uke tidligere. En lineær regresjon og en `HistGradientBoostingRegressor` (HGB) ble først trent med kalender og trafikklag ved $t-1$, $t-2$, $t-24$ og $t-168$. På 2024-valideringen fikk lineær regresjon MAE 322,45, HGB 103,28 og baselinen 200,78. HGB ble valgt og fikk MAE 106,22 ved én måling på 2025. Sammenligningene brukte 8 231 felles rader i 2024 og 8 760 i 2025. Etter modellvalget ble HGB trent på trenings- og valideringsdata samlet før 2025-testen, slik at testresultatet ikke påvirket valget.

Helligdagsindikatorer reduserte gjennomsnittlig CV-MAE i 2022–2023 fra 120,03 til 119,69. To værforsøk ga derimot ingen forbedring: en enkel værmodell fikk MAE 106,73 mot 103,41 uten vær på de samme 2024-radene, og en avledet værpakke fikk CV-MAE 124,43 mot 119,69. Vær ble derfor forkastet før sluttmodellen ble bestemt. De forsinkede værvariablene ble valgt for å unngå at modellen fikk observasjoner som ikke ville vært publisert på prognosetidspunktet.

Den første frosne kalender-HGB-en fikk MAE 102,35 på 2025, men krevde de ferske lagene $t-1$ og $t-2$, som ikke alltid er publisert når prognosen lages. Tre forhåndsdefinerte, latensrobuste lagpakker ble derfor sammenlignet i 2022–2023-CV. Pakkene $(24, 168)$, $(24, 48, 168)$ og $(24, 168, 336)$ fikk MAE 134,88, 133,77 og 135,80. Vinneren $(24, 48, 168)$ ble fryst som `traffic-hgb-latency-robust-v1`. Den ofrer helt fersk trafikkinformasjon for å kunne brukes selv ved publiseringsforsinkelse. Kandidatlisten og `random_state=42` var bestemt på forhånd, og ingen hyperparametere ble valgt fra den senere 2026-testen.

3.2 Kronologisk evaluering

Tilfeldig oppdeling ville blandet fortid og fremtid. Modellvalget brukte derfor voksende treningsvinduer med validering i 2022 H2, 2023 H1 og 2023 H2. Etter at 2025 var låst for videre valg og kandidaten var fryst, ble modellen trent på 2022–2025 og evaluert én gang på den nye testperioden 2026 H1. Sluttresultatet ble ikke brukt til ny finjustering.

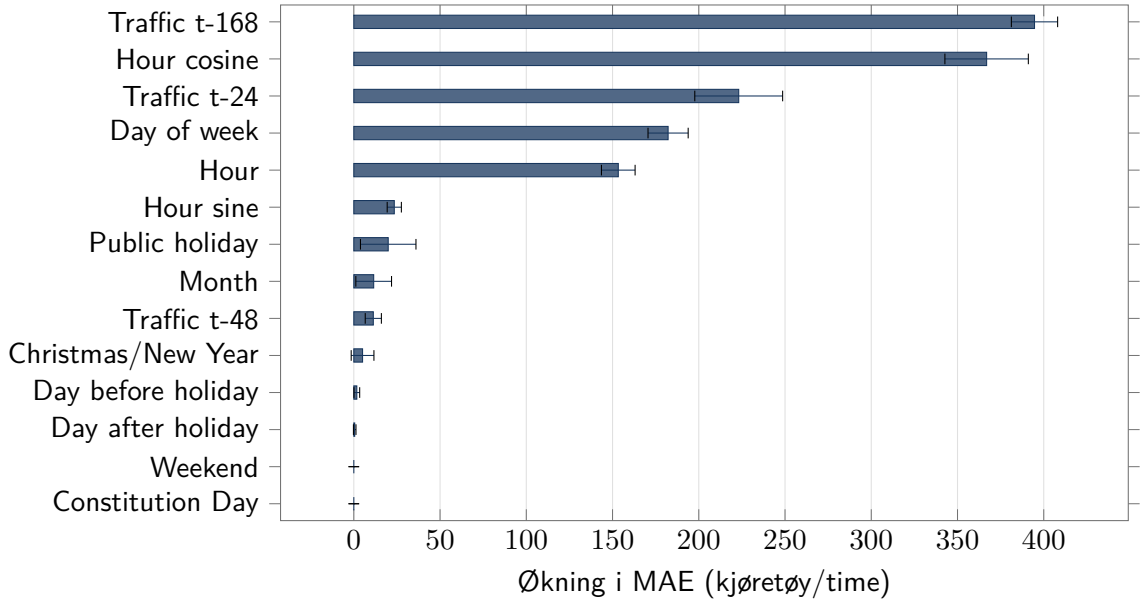
Tabell 1 sammenligner modell og baseline på de samme 4 343 radene. Modellen reduserer MAE med 102,98 kjøretøy per time, tilsvarende 48,6 prosent. RMSE ligger over MAE fordi enkelte timer har store feil.

Tabell 1: Sluttevaluering på den tidligere ubrukte perioden 2026 H1.

Modell	MAE	RMSE	Rader
Latensrobust HGB	108,81	161,85	4 343
Forrige uke	211,79	454,47	4 343

3.3 *Feature importance*

Permutasjonsbasert *feature importance* ble beregnet med MAE i de tre kryssvalideringsperiodene. Hver feature ble stokket 30 ganger i hver valideringsperiode. Figur 3 viser hvor mye feilen øker når sammenhengen med target brytes. Analysen ble gjort etter at kandidaten var fryst og ble ikke brukt til modellvalg.



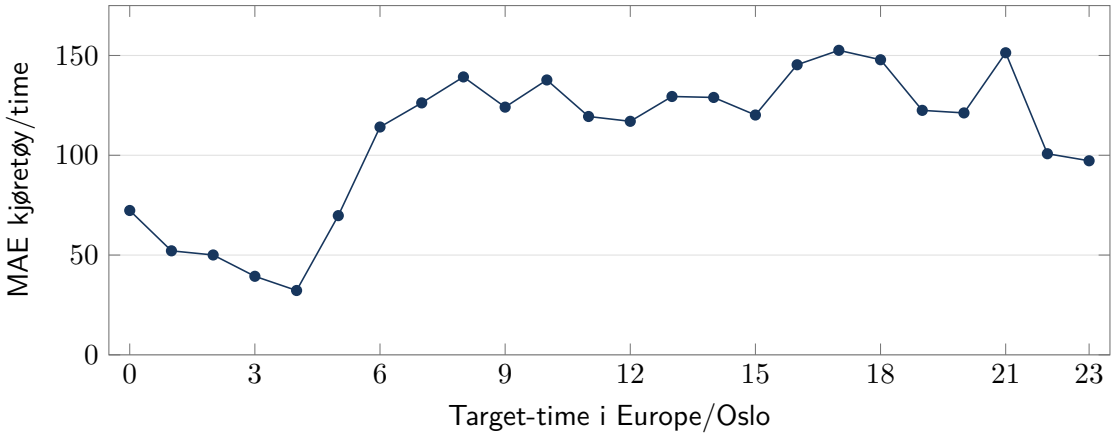
Figur 3: Permutasjonsbasert *feature importance* for den frosne, latensrobuste modellen, beregnet med tidsserie-kryssvalidering. Feilindikatorene viser standardavvik over 90 permutasjoner per variabel, fordelt på tre valideringsperioder.

Modellen støtter seg særlig på ukerytme, døgnsyklus og trafikken ett døgn tidligere. Lagget på 168 timer ga størst gjennomsnittlig MAE-økning med 394,64, etterfulgt av time-cosinus med 366,88 og lagget på 24 timer med 223,15. Importance viser modellavhengighet, ikke årsak. Korrelasjon mellom tidsvariabler og trafikklag kan dessuten fordele betydningen mellom dem. Konklusjonen om vær kommer fra de separate væreforsøkene.

3.4 Feilanalyse

Figur 4 viser MAE etter target-time i 2026 H1. Feilen er lavest kl. 04 med 32,24 og høyest kl. 17 med 152,58 kjøretøy per time. Dag- og kveldstimer er gjennomgående vanskeligere enn natten. Kl. 21 har også høy MAE, 151,36, så utfordringen er ikke begrenset til vanlig rushtrafikk.

Etter ukedag varierer MAE fra 97,05 på tirsdag til 121,89 på lørdag. Analysen viser når feilen er størst, men ikke årsaken. RMSE 161,85 mot MAE 108,81 viser også noen større avvik, så gjennomsnittsfeilen er ingen garanti for en enkelt time. Mulige forbedringer, som hendelsesdata, må vurderes i en ny kronologisk valideringsrunde og måles på en senere, urørt testperiode.



Figur 4: Sluttmodellens MAE per time som predikeres i 2026 H1. Figuren genereres fra prosjektets dokumenterte sluttrapport.

4 Deployment

4.1 Bygging, lagring og lasting

Sluttproduktet er en lokal Streamlit-demonstrasjon, ikke en offentlig driftet tjeneste. `make build-app-model` laster ned og normaliserer trafikkdata, trener den frosne modellen og lagrer modell og metadata lokalt. Artefakten er ignorert av Git og må bygges fra dokumenterte kommandoer. Appen gir byggekommandoen dersom modellen mangler eller ikke kan leses.

Modellpakken inneholder den trente HGB-en, den ordnede featurelisten og metadata om modellversjon, lagpakke, treningsperiode og datakilde. Treningsskriptet gjenskaper CV-rapporten og sluttevalueringen før modellen trenes på 34 159 gyldige rader før 1. januar 2026.

4.2 Brukerflyt og prognose

Appen startes med `streamlit run app/streamlit_app.py`. Streamlit er et Python-rammeverk for interaktive dataapplikasjoner [5]. Brukeren velger «Neste time» eller et historisk tidspunkt og trykker «Vis prognose». Prognoseintervallet vises i `Europe/Oslo` med UTC-offset. Historiske valg begrenses til reelle lokale klokketimer, også ved overgang mellom sommer- og vintertid.

Ved hvert klikk lastes modellen, og nødvendig historikk hentes fra Traffic Data API. Appen bygger kalenderfeatures og slår opp trafikk ved $t - 24$, $t - 48$ og $t - 168$. Hvis alle verdiene finnes, vises forventet biltrafikk og de siste 72 timene i en graf. Målegap vises som hull. Mangler et nødvendig lag, gis ingen prediksjon.

Grensesnittets sammenligning bruker observert trafikk ved target minus 168 timer, altså $t - 167$, mens modellens ukesfeature er knyttet til $t - 168$. Sammenligningen er valgfri og blokkerer ikke en ellers gyldig prognose. Appen viser også modellinput, datakilde og siste tilgjengelige observasjon.

4.3 Feilhåndtering, demonstrasjon og drift

Appen skiller mellom manglende modell, API-feil og utilstrekkelig historikk og gir brukeren et neste steg. Historiske prognoser bruker data som er tilgjengelige nå; de rekonstruerer ikke tidligere publiseringstilstand og er ikke nye testresultater.

En videodemonstrasjon er lenket fra prosjektets README: Bergen Traffic Predictor videodemonstrasjon. Løsningen kan kjøres på en vanlig lokal datamaskin med Python 3.11 eller nyere.

Hvert klikk gjør et nytt API-kall; denne versjonen bruker ikke mellomlager eller lokal database. Det gjør demonstrasjonen enkel, men gir avhengighet av API-ets tilgjengelighet og responstid.

Før reell drift bør systemet logge API-feil, manglende lag, dataalder, modellversjon og prediksjoner. Når fasiten blir tilgjengelig, bør MAE og RMSE følges over tid for å skille datafeil fra modelldrift. Vedvarende avvik kan skyldes sensorendring, vegomlegging eller endret reisemønster. En ny modellversjon må velges med kronologisk validering og evalueres på en ny, urørt periode før den tas i bruk. Automatisk retrening bør ikke innføres uten en godkjenningsmekanisme som hindrer at målegap eller unormale perioder blir gjort til ny normal.

5 Referanser

Kildene dokumenterer datatjenestene og bibliotekene løsningen bygger på. De numeriske prosjektresultatene er egne eksperimenter som kan gjenskapes fra skriptene og rapportene i repositoryet.

[1] Statens vegvesen. *Trafikkdata-API*. Beskrivelse av innhold, tidsoppløsning, kvalitetsparametere og lisens. URL: https://dataut.vegvesen.no/nb/dataset/trafikkdata/resource/968a10a7-f704-4cd7-9795-de69e8cad2bc (sjekket 24.10.2026).

[2] Statens vegvesen. *Trafikkdataportalen*. URL: https://trafikkdata.atlas.vegvesen.no/ (sjekket 24.10.2026).

[3] MET Norway. *Frost API How to use Frost*. URL: https://frost.met.no/howto.html (sjekket 24.10.2026).

[4] MET Norway. *Frost API Relationship between referenceTime timeOffset and timeResolution*. URL: https://frost.met.no/concepts2.html (sjekket 24.10.2026).

[5] Streamlit. *Streamlit documentation*. URL: https://docs.streamlit.io/ (sjekket 24.10.2026).